

FutureX × Raven 三档试跑报告

futurex-20260817T191457 · 12 道二元题 × 3 个模型档位 = 36 个作业 (36 完成)

运行 ID	futurex-20260817T191457
执行模式	live-paid (explicit --allow-paid)
数据集版本	2841bff13f6d2f679298ce7007e91ae585f4ade1
题库文件	/Users/Aincrad/dev-proj/raven-gonna-test/runtime-artifacts/futurex/2026-08-19/questions.json
题库 SHA-256	1efb0dfd1f659482cf69d3d8fbb225fec9de92b7a1f8b72ede6fa40fdcf0a465
证据截止 (as-of)	2026-08-17T19:14:57+08:00
批次状态	completed
报告生成时间	2026-08-17T13:32:07.848Z

1 · 适配方法：FutureX 题目 → Raven 引擎

Raven 引擎只会做一件事：对一个命题算出校准过的概率 $P(\text{Yes})$ 。FutureX 收的是字面答案。适配层负责在两者之间做无损的那部分转换，并在做不到无损时主动拒答，而不是编一个答案。

1.1 全库 80 道题的分类结果

题型	输出协议	题数	本轮处理
numeric	boxed_numeric	32	主动阻断
single_choice	boxed_option_letters	25	主动阻断
open_text	boxed_open_text	7	主动阻断
binary	boxed_option_letters	6	本轮已跑
binary	boxed_yes_no	6	本轮已跑
multi_choice	boxed_entity_set	3	主动阻断
ranking	boxed_ranked_list	1	主动阻断

12 / 80 道可由当前二元引擎执行；其余 68 道被 executableByRaven: false 挡下。

1.2 例题 A — 能直接跑（原生二元）

Will Analog Devices report fiscal Q3 2026 adjusted diluted EPS of at least US\$3.00?

1a7b455ee6b6976885a464e6 · level 1 · 要求 \boxed{Yes} 或 \boxed{No}

适配三步：① 剥掉题面里的 (resolved around ...) 还原成干净预测问题，把 end_time 钉为结算边界；② 注入 as-of 冻结约束（只用 2026-08-17T19:14:57+08:00 之前的信息），防止跑的时候搜到已公布结果；③ Raven 输出 $P(\text{Yes})=0.xx$ ，概率原样留档，再按 0.5 阈值压成字面答案。

代价：FutureX 只收 1 bit，概率信息在提交时被丢弃。所以概率我们自己留档，用于事后算 Brier 与校准曲线。

1.3 例题 B — 跑不了，会被主动拦下（数值题）

Keysight fiscal Q3 2026: what exact revenue will it report?

a430f7920c8a544f428a57b1 · level 4 · 只收 `revenue_usd_millions` 的精确数值，不带单位、逗号、区间

为什么不能套二元：这题要的是连续取值上的一个点估计，不是某个命题的概率。用二元引擎硬答只能瞎猜，且没有任何校准意义。

正确做法（已写进 `adaptationPlan`，本轮未实现）：用历史财报 + 分析师一致预期构建营收的预测分布，再按评分标准取最优点估计（绝对误差取中位数，平方误差取均值）。

当前行为：`executableByRaven: false`；带 `--allow-paid` 时直接报错退出。这是刻意的 `fail-closed`。

本轮范围：只跑 12 道二元题（6 道 `boxed_option_letters` + 6 道 `boxed_yes_no`），两种协议走完全相同的引擎路径，只在最后一步的答案序列化上分叉。5 类非二元题型全部未执行。

2 · 三档对比：同一题，三个模型档位

题目	截止	Urd / low		Verdandi / medium		Skuld / high		极差
		P(Yes)	答案	P(Yes)	答案	P(Yes)	答案	
Will Armand Duplantis clear 6.20m at the 2026 Athletissima men's pole vault?	08–21T05:00	94.3%	A	2.7%	B	2.0%	B	92.3pp
Will Analog Devices report fiscal Q3 2026 adjusted diluted EPS of at least US\$3.00?	08–19T20:00	91.4%	Yes	95.5%	Yes	99.0%	Yes	7.6pp
Will BILL report fiscal Q4 2026 non–GAAP diluted EPS of at least US\$0.50?	08–20T08:00	99.0%	Yes	98.7%	Yes	99.0%	Yes	0.3pp
Will BILL report fiscal Q4 2026 total revenue of at least US\$400 million?	08–20T08:00	93.7%	Yes	98.8%	Yes	99.0%	Yes	5.3pp
Will Shohei Ohtani hit at least one home run in Los Angeles Dodgers at Colorado Rockies on 2026–08–19 (U.S....	08–21T12:00	36.2%	No	32.2%	No	27.5%	No	8.7pp
Will SpaceX deploy all 29 planned Starlink satellites from its 20 August 2026 Cape Canaveral mission by 21...	08–21T12:00	87.7%	Yes	88.8%	Yes	88.8%	Yes	1.2pp
Will the exact phrase “artificial intelligence” appear at least once in the published HTML article body of...	08–20T03:00	95.7%	A	97.4%	A	99.0%	A	3.3pp
Will SpaceX deploy all 24 planned Starlink satellites from its 19 August 2026 Vandenberg mission by 20 August...	08–20T12:00	93.2%	Yes	91.2%	Yes	96.3%	Yes	5.1pp
Will a Canadian pair reach the semifinals of the 2026 Beach Pro Tour Elite16 Montréal?	08–24T12:00	87.6%	A	82.8%	A	71.9%	A	15.7pp
Will Google Pixel 11 be on shelves at the Google Store and retail partners on 20 August 2026?	08–20T23:59	73.4%	A	99.0%	A	99.0%	A	25.6pp
Will Lowe's report fiscal Q2 2026 adjusted diluted EPS of at least US\$4.00?	08–19T21:05	94.5%	A	93.6%	A	98.0%	A	4.5pp
Will China's one–year Loan Prime Rate remain 3.00% in the 20 August 2026 publication?	08–20T09:35	83.5%	A	94.0%	A	99.0%	A	15.5pp

底色标黄 = 三档给出的字面答案不一致。极差 = 三档 P(Yes) 的最大值减最小值。

1 道题三档答案分歧，这是最值得人工复核的入口—— 它们要么信息真的稀薄，要么低档位漏掉了关键证据：

- Will Armand Duplantis clear 6.20m at the 2026 Athletissima men's pole vault? (极差 92.3pp · A / B / B)

3 · 各档开销与行为画像

档位	模型	effort/轮上限	完成	均值 P(Yes)	判 Yes 比例	均轮数	均证据数	总耗时 (分)	输出 token	成本
Urd / low	claude-haiku-4-5-20251001	low / 1	12	85.8%	91.7%	1.0	4.4	56.6	210,130	\$8.37
Verdandi / medium	claude-sonnet-5	medium / 2	12	81.2%	83.3%	2.0	6.8	56.0	174,375	\$38.21
Skuld / high	claude-opus-5	high / 3	12	81.5%	83.3%	2.5	13.3	136.8	393,325	\$53.94

成本与 token 直接取自 Claude CLI 的 result 事件；CLI 未上报的字段一律显示"不可用"，不补零。"判 Yes 比例"偏离 50% 很远时要留意档位是否存在系统性的乐观/悲观偏置。

本报告由 scripts/forecast/futurex-report.ts 从 batch-result.json 生成，未经人工编辑。每个作业的完整状态与推理报告见 runtime-artifacts/futurex-adapter/futurex-20260817T191457/<档位>/<题目 ID>/。所有预测均在各题 end_time 之前、以 as-of 冻结的信息做出。